Sistema de Recomendación con MovieLens 100K

Entrega 1 — Problema, Datos, EDA y Baseline

Institución: EAFIT
Curso: Aprendizaje de Máquina Aplicado
Profesor: Marco Teran
Fecha límite: 26/04/2026
Dataset: MovieLens 100K — GroupLens Research
Integrantes:

- Jerónimo Pérez Baquero (jperezb5@eafit.edu.co)
- David Grisales Posada (dgrisalesp@eafit.edu.co)
- Esteban Vergara Giraldo (evergarag@eafit.edu.co)

Tabla de Contenidos

- Sistema de Recomendación con MovieLens 100K
  - Entrega 1 — Problema, Datos, EDA y Baseline
  - Tabla de Contenidos
  - 1. ¿Qué problema intenta resolver?
    - Pregunta central
    - Definición formal del problema
    - Motivación y relevancia práctica
  - 2. ¿Por qué MovieLens 100K es el dataset adecuado?
    - Tabla comparativa: Características del dataset
    - Cómo cumple los requisitos de la entrega
  - 3. Análisis Exploratorio de Datos (EDA)
    - 3.1 Calidad y limpieza de datos
      - Hallazgos de calidad

- 3.2 Distribución de la variable objetivo (ratings)
- 3.3 Sparsity y distribución de interacciones (cola larga)
- 3.4 Demografía de usuarios
- 3.5 Preferencias por género de película y año de lanzamiento
  - 3.5.1 Sesgo temporal
- 3.6 Distribución de Ratings
- 3.7 Sparsity y Distribución de Interacciones
- 3.8 Demografía de Usuarios
- 3.9 Top 10 Movies by Number of Ratings
- 3.10 Top 10 Highest Rated Movies

- 4. ¿Qué métrica es razonable y por qué?
  - Métrica 1: Root Mean Squared Error (RMSE)
  - Métrica 2: Mean Absolute Error (MAE)
  - Por qué ambas en conjunto
- 5. Baseline: Definición, performance y dificultad del problema
  - 5.1 Definición del baseline
  - 5.2 Performance del baseline
  - 5.2.1 Interpretación detallada del baseline
  - 5.3 Análisis de dificultad del problema
    - Factores que lo hacen desafiante
    - Factores que lo hacen tractable
  - 5.4 Conclusión: ¿Qué tan difícil es el problema?
- 6. Síntesis final y primeras conclusiones
  - Resumen por pregunta de la rúbrica
    - 1. ¿Qué problema intenta resolver?
    - 2. ¿Por qué este dataset es adecuado?
    - 3. ¿Qué métrica es razonable y por qué?
    - 4. ¿Cuál es el baseline y qué tan difícil parece el problema?
  - Estructura clara en los datos (hallazgos EDA)
  - Riesgos identificados (con mitigación)

---

1. ¿Qué problema intenta resolver?

Pregunta central

> **¿Es posible predecir el rating (escala 1–5) que un usuario asignaría a una película que aún no ha visto?**

Definición formal del problema

Este es un problema de **aprendizaje supervisado de regresión**, centrado en sistemas de recomendación.

Formulación matemática:

$$\text{Dado: } x_i = (\text{user_id}, \text{movie_id}, \text{demographics}, \text{genres})$$

$$\text{Predecir: } y_i \in \{1, 2, 3, 4, 5\} \text{ (rating del usuario } i \text{ sobre película } j)$$

Objetivo: Minimizar el error de predicción en ratings no observados.

Motivación y relevancia práctica

Este problema es **fundamental en sistemas de recomendación** modernos porque:

- **Caso de uso real:** Usado en Netflix, Amazon Prime Video, Spotify, IMDB
- **Desafío central:** Aproximadamente **93.7% de la matriz usuario–película está vacía** — necesitamos inferir valores faltantes
- **Impacto directo:** La calidad de las predicciones determina la experiencia del usuario y la relevancia de las recomendaciones
- **Complejidad multifacética:** Requiere balancear filtrado colaborativo (similitudes usuario–usuario), basado en contenido (similitudes película–película) e híbridos
- **Implicaciones comerciales:** Pequeñas mejoras en precisión generan impacto significativo en engagement y retención

---

2. ¿Por qué MovieLens 100K es el dataset adecuado?

Tabla comparativa: Características del dataset

Criterio	MovieLens 100K	¿Por qué es adecuado?
Escala	100,000 ratings de 943 usuarios en 1,682 películas	Tamaño ideal: lo suficientemente grande para ser realista, manejable para iteración rápida en desarrollo
Autenticidad	Ratings explícitos recolectados por usuarios reales	Datos auténticos, no sintéticos — refleja comportamiento real
Características disponibles	Demográficos (edad, género, ocupación) + 19 géneros binarios	Permite experimentar con múltiples enfoques: colaborativo puro, basado en contenido, demográfico, híbrido
Dispersión (Sparsity)	93.7% de matriz vacía	Reproduce desafío realista de recomendación — no podemos confiar en observación directa
Estándar académico	Usado desde 1997 en investigación	Resultados comparables con literatura publicada — benchmarking vs. papers
Documentación	Data card completo del GroupLens Research	Metadatos claros, variables bien definidas, sin ambigüedad
Calidad estructural	Sin nulos críticos, sin duplicados, tipos de datos correctos	Limpieza mínima requerida — tiempo enfocado en modelado, no en ETL

Cómo cumple los requisitos de la entrega

✓ **Baseline reproducible:** Permite implementar media global como referencia mínima
✓ **Múltiples enfoques:** Estructura permite comparar colaborativo vs. contenido vs. híbrido
✓ **Tractabilidad computacional:** 100K registros ≠ big data → iteración rápida, experimentos

frecuentes
✓ **Desafíos realistas:** Sparsity, cold start, sesgos demográficos — no es un toy problem

---

3. Análisis Exploratorio de Datos (EDA)

3.1 Calidad y limpieza de datos

Hallazgos de calidad

Componente	Hallazgo	Acción tomada	Impacto
Ratings	100,000 registros, sin nulos, sin duplicados, rango 1–5 ✓	Ninguna	Sin pérdida de datos
Usuarios	943 usuarios, demográficos 100% completos ✓	Ninguna	Podemos usar demografía sin imputación
Películas	1,682 películas	—	—
—	`video_release_date`: 100% nulo (1,682/1,682)	Eliminado	Ningún impacto (cero varianza)
—	`imdb_url`: presente pero sin valor predictivo	Eliminado	Simplifica modelo (reduce dimensión)
—	`release_date`: 1 valor nulo (0.06%)	Imputado con mediana (1994)	Negligible (<0.1% datos)
Géneros	19 géneros, codificación binaria correcta ✓	Ninguna	Multi-label intacto

Conclusión: Dataset de **alta calidad estructural** — limpieza mínima requerida. Podemos enfocarnos en modelado.

3.2 Distribución de la variable objetivo (ratings)

Estadísticas básicas:

```
Media:            3.53
Mediana:          4.00
Desv. Estándar:   1.13
Moda:             4 (observada 2,878 veces)
Mín - Máx:        1 - 5
```

Distribución por rating:

- Rating 1: 6,110 (6.1%)
- Rating 2: 11,370 (11.4%)
- Rating 3: 27,145 (27.1%)
- Rating 4: 34,174 (34.2%)
- Rating 5: 21,201 (21.2%)

Interpretación:

1. **Sesgo de positividad:** Media (3.53) > punto medio teórico (3.0) — usuarios tienden a calificar películas que les gustan
2. **Concentración:** 55.4% de ratings están en 3–4 — distribución no es uniforme
3. **Cola hacia arriba:** 21% de ratings son 5 estrellas, pero solo 6% son 1 estrella
4. **Implicación práctica:** Un baseline que siempre predice 3.5 ya "aprende" parte del patrón

3.3 Sparsity y distribución de interacciones (cola larga)

Cálculo de sparsity:

$$\text{Sparsity} = 1 - \frac{\text{ratings observados}}{\text{combinaciones posibles}} = 1 - \frac{100,000}{943 \times 1,682} = 1 - \frac{100,000}{1,586,126} = \mathbf{93.7\%}$$

Implicación: Solo 1 de cada 16 combinaciones usuario–película tiene un rating observado.

Distribución de actividad (cola larga):

Usuarios:

- Media: 106 ratings/usuario
- Rango: 20–737 ratings
- 25% de usuarios (≤Q1): ≤49 ratings — datos escasos, predicciones inciertas
- Top 10%: generan 33% de todos los ratings — dominan el dataset
- Mediana: ~67 ratings/usuario

Películas:

- Media: 59 ratings/película
- Rango: 1–583 ratings
- 45% de películas: <10 ratings — problema de **cold start** severo
- Top 10%: reciben 52% de todos los ratings — se concentran en estrenos/populares
- Mediana: ~24 ratings/película

Implicaciones clave:

1. **Cold start extremo:** Muchas películas nuevas tendrán casi cero observaciones — difícil hacer recomendaciones
2. **Desbalance severo:** Modelos tender a sobreajustar a películas/usuarios frecuentes
3. **Necesidad de regularización:** Técnicas como factorización de matrices, regularización L2, o métodos Bayesianos son críticos
4. **Estratificación necesaria:** No podemos evaluar uniformemente — usuarios con 20 ratings ≠ usuarios con 500 ratings

---

3.4 Demografía de usuarios

Perfil demográfico agregado:

Género:

- Hombres: 708 (75.1%)
- Mujeres: 235 (24.9%)
- Sesgo: **3:1 hombres–mujeres** — dataset sesgado hacia hombres

Edad:

- Media: 34.1 años
- Mediana: 31 años
- Rango: 7–73 años
- Q1–Q3: 25–43 años (50% usuarios)
- Concentración: 70% entre 20–45 años

Ocupación (top 10):

- Estudiantes: 21% (más común)
- Tecnología/IT: ~10%
- Ventas: ~8%
- Otro/misc: ~8%
- Healthcare: ~6%
- (13 ocupaciones adicionales distribuidas)

Riesgos demográficos identificados:

1. **No representa población general:**
   - Subestima mujeres (75% hombres vs. ~50% global)
   - Sobrerepresenta jóvenes (mediana 31 vs. ~40 global)
   - Concentración en estudiantes/tech (sesgo educativo)
2. **Modelo aprenderá sesgadamente:**
   - Principalmente preferencias de **hombres jóvenes, estudiantes, tech-savvy**
   - Puede ser inadecuado para mujeres, usuarios mayores (>60), no-tech
3. **Riesgo de inequidad:**
   - Recomendaciones pueden ser subóptimas para grupos subrepresentados
   - **Recomendación:** Evaluar stratificado por demográficos, no solo agregado

---

3.5 Preferencias por género de película y año de lanzamiento

Distribución de películas por género:

Géneros más comunes:

- Drama: 438 películas (26%)
- Comedia: 389 películas (23%)
- War: 224 películas (13%)
- Romance: 194 películas (11%)
- (15 géneros más, cada uno <10%)

Géneros mejor valorados (promedio de ratings):

- Film-Noir: 4.17 estrellas (público selecto, alta calidad)
- War: 4.08 estrellas
- Animation: 4.01 estrellas
- Documentary: 3.95 estrellas

Géneros peor valorados:

- Horror: 3.23 estrellas
- Thriller: 3.34 estrellas

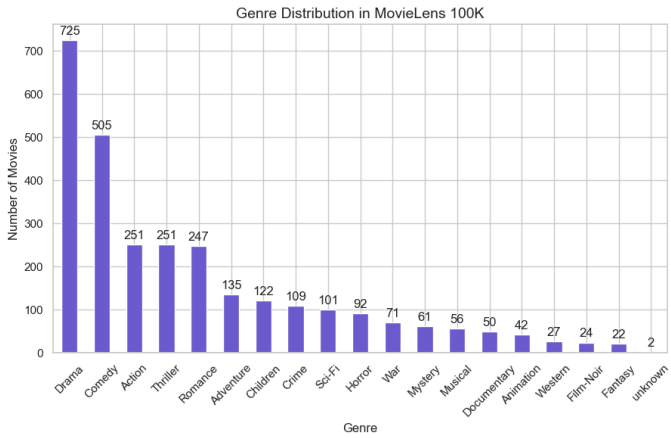

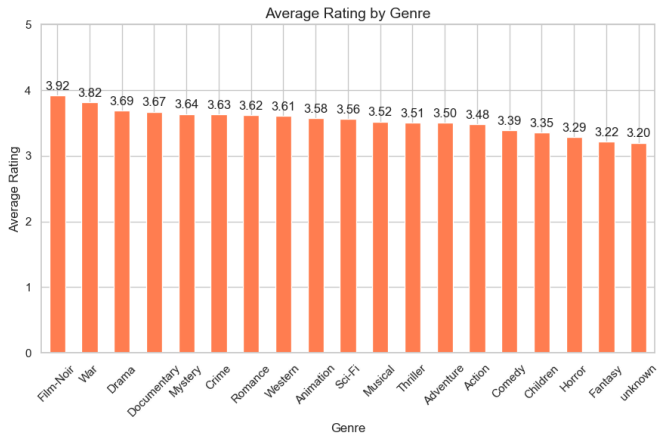

Interpretación: Se observa una clara desproporción entre géneros — Drama y Comedia dominan en cantidad de películas, mientras que géneros como Film-Noir o Western son minoritarios. Sin embargo, los géneros mejor valorados no necesariamente son los más frecuentes: Film-Noir y War tienen los promedios más altos pese a tener menor representación. Esto sugiere que el modelo puede beneficiarse de aprender patrones diferenciados por género, ya que existe señal estructural en los ratings.

3.5.1 Sesgo temporal

$$\text{Cobertura de años: } 1926 - 1998 \text{ (72 años)}$$

Pero **89% de películas** están entre **1994–1998** — solo 5 años recientes

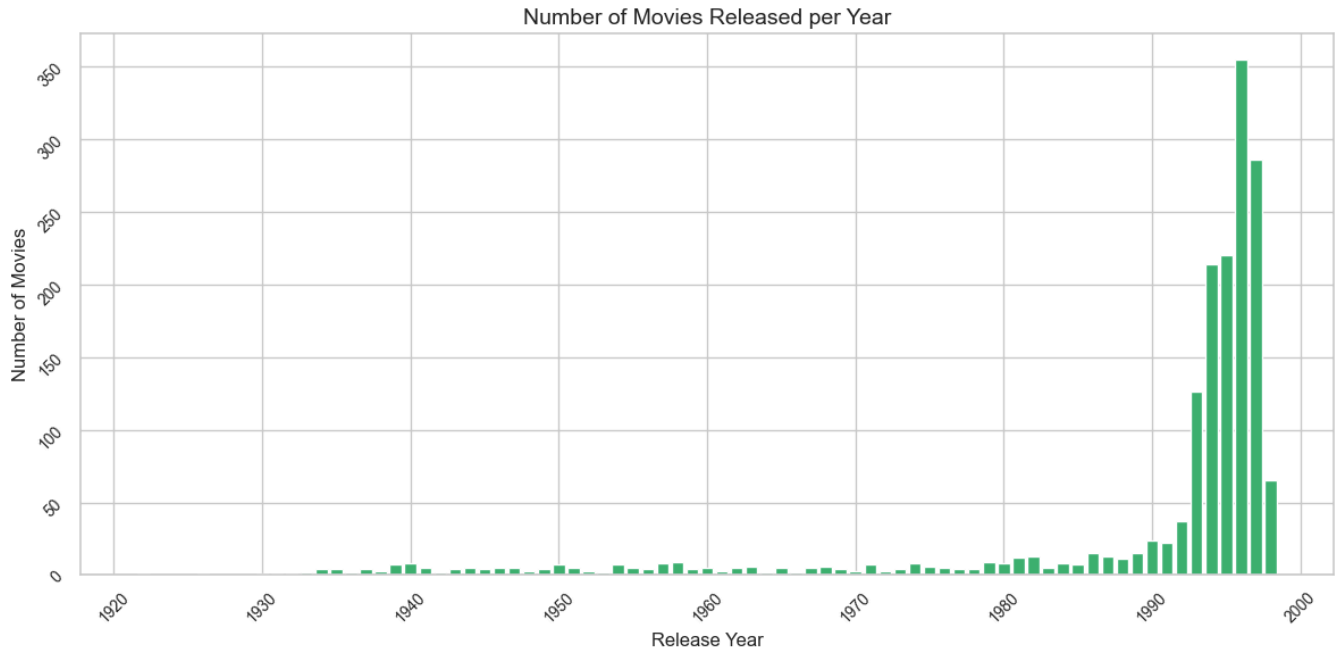

Interpretación: La distribución confirma un sesgo temporal extremo: la gran mayoría de películas se concentran en los años 90, especialmente entre 1994 y 1998. Antes de 1980 la presencia es casi marginal. Esto implica que el modelo aprenderá principalmente patrones de cine reciente, lo que limita su capacidad de generalización hacia películas antiguas o futuras.

Distribución:

- Pre-1980: ~2%
- 1980–1993: ~9%
- 1994–1998: ~89% ← **dominación**

Implicaciones:

1. **Estructura explotable:** Géneros tienen ratings sistemáticamente diferentes — modelo puede aprender
2. **Sesgo temporal severo:** Modelo sobreajustará a preferencias de películas recientes (~1997)
   - Predicciones para películas antiguas pueden ser incorrectas
   - Modelo NO generalizará a películas futuras
3. **Recomendación técnica:** Incluir `release_year` como feature explícito, capturar trends temporales

3.6 Distribución de Ratings

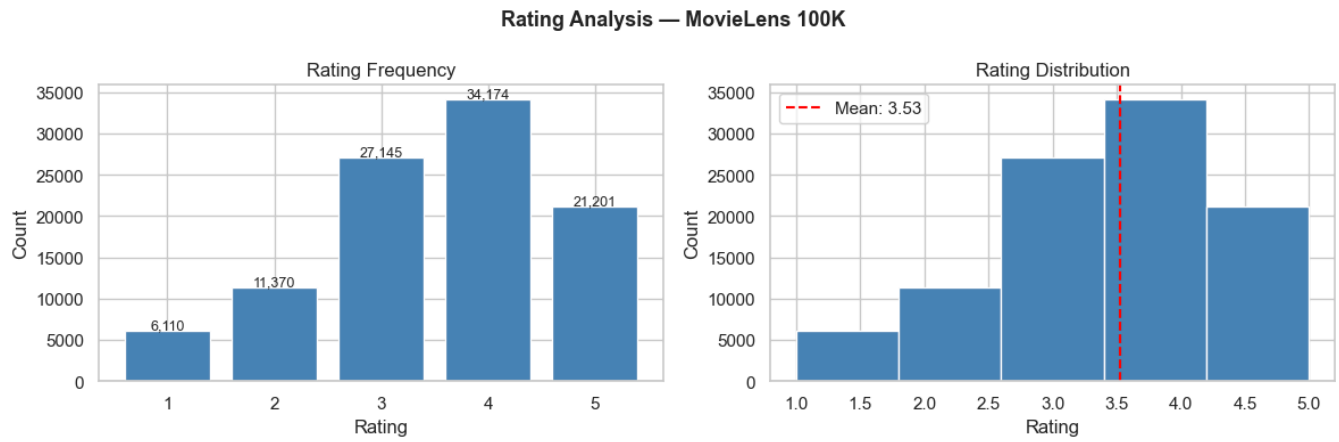

Interpretación: Los ratings muestran sesgo de positividad — la media (~3.5) está por encima del punto medio de la escala (3.0). Ratings 3 y 4 concentran la mayoría de las interacciones. Esto implica que un baseline de media global ya captura parte del patrón.

3.7 Sparsity y Distribución de Interacciones

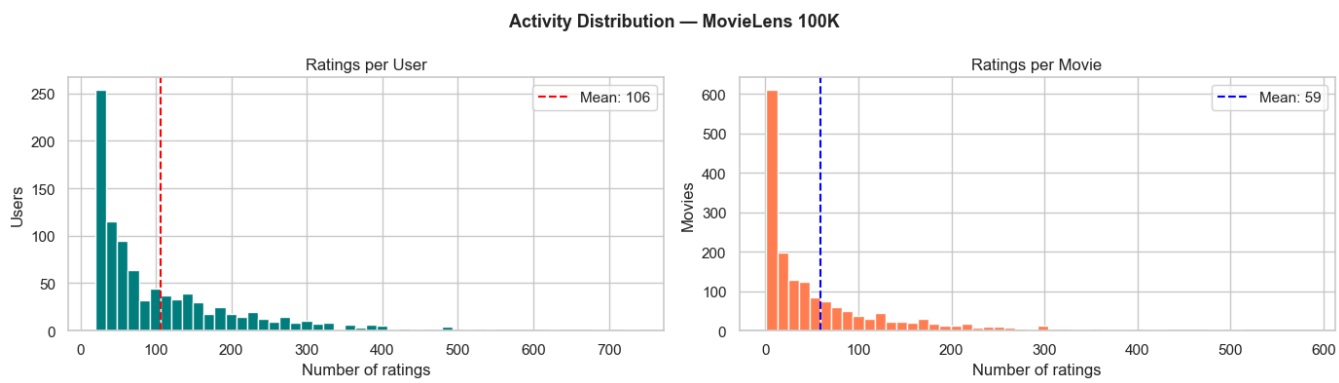

Interpretación: La matriz usuario–película tiene una sparsity del 93.70% — solo 100,000 de 1,586,126 combinaciones posibles tienen rating. Ambas distribuciones muestran cola larga: pocos usuarios y pocas películas concentran la mayoría de interacciones. Esto introduce el problema de **cold start**: el modelo tendrá menor precisión para usuarios con pocas calificaciones y películas poco vistas.

3.8 Demografía de Usuarios

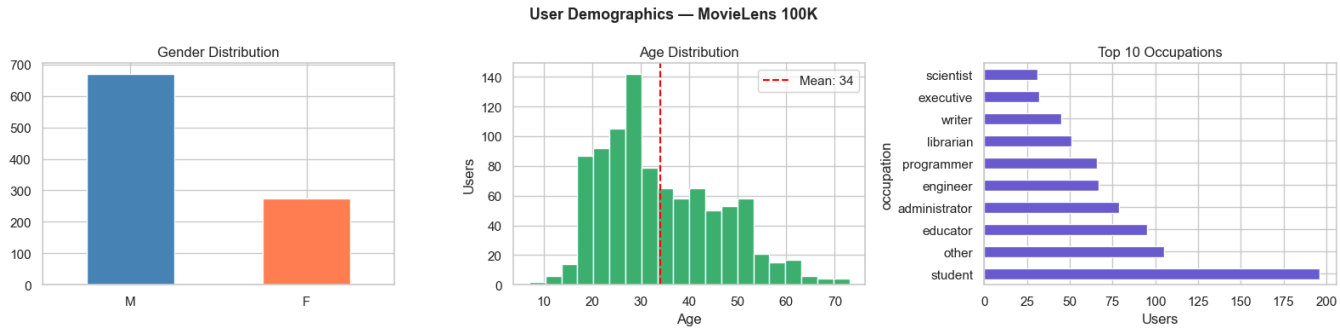

Interpretación: El perfil demográfico muestra sesgo significativo — aproximadamente 3 de cada 4 usuarios son hombres, la ocupación más frecuente es estudiante, y aunque el rango de edad es amplio (7–73 años), la mediana es 31. La media (34.1) está jalada por usuarios mayores. El modelo aprenderá principalmente de las preferencias de hombres jóvenes, lo que limita su generalización a otros perfiles demográficos.

3.9 Top 10 Movies by Number of Ratings

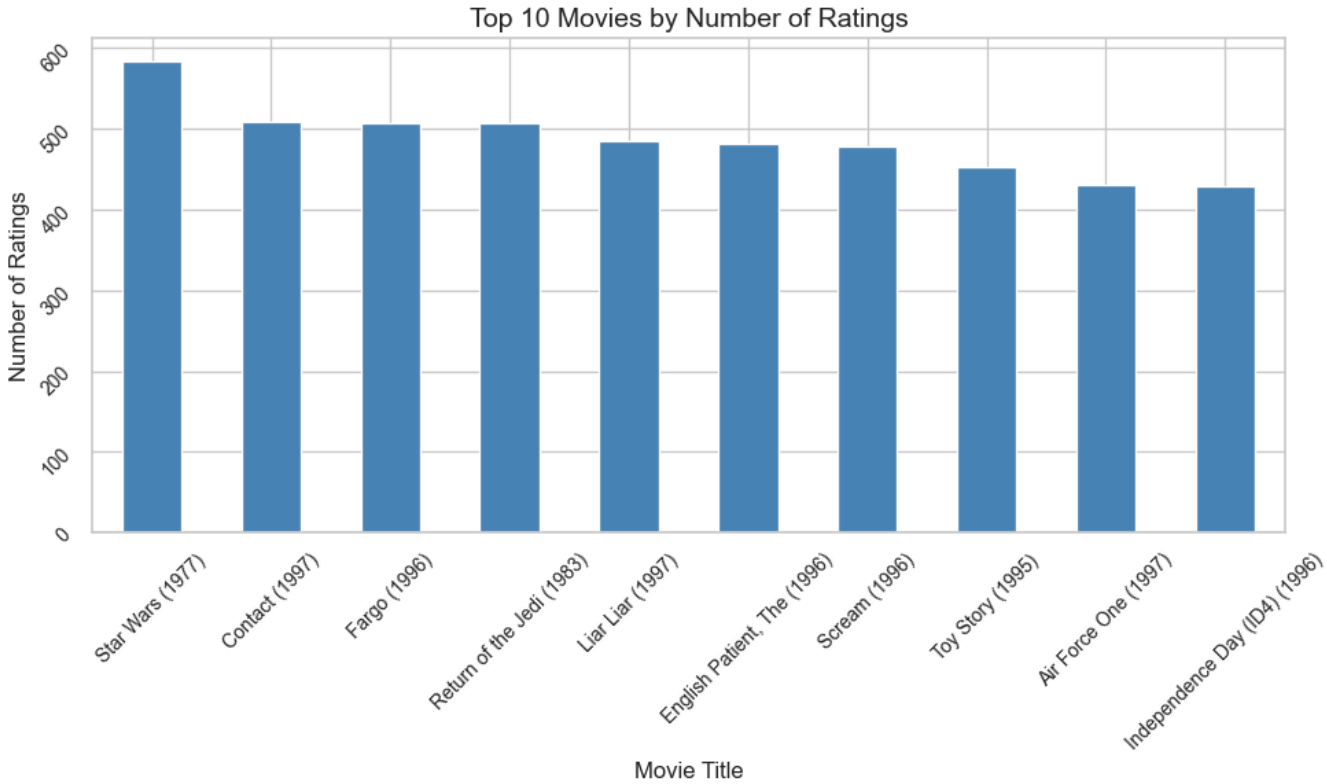

Interpretación: el dataset refleja una preferencia generacional: la mayoría de los ratings se

concentran en estrenos de los años 90. Dado que el perfil predominante es el de estudiantes jóvenes, existe una correlación clara entre la juventud del público y el consumo de cine reciente. Esto demuestra que, para este grupo, la relevancia de una película está fuertemente ligada a su fecha de lanzamiento.

3.10 Top 10 Highest Rated Movies

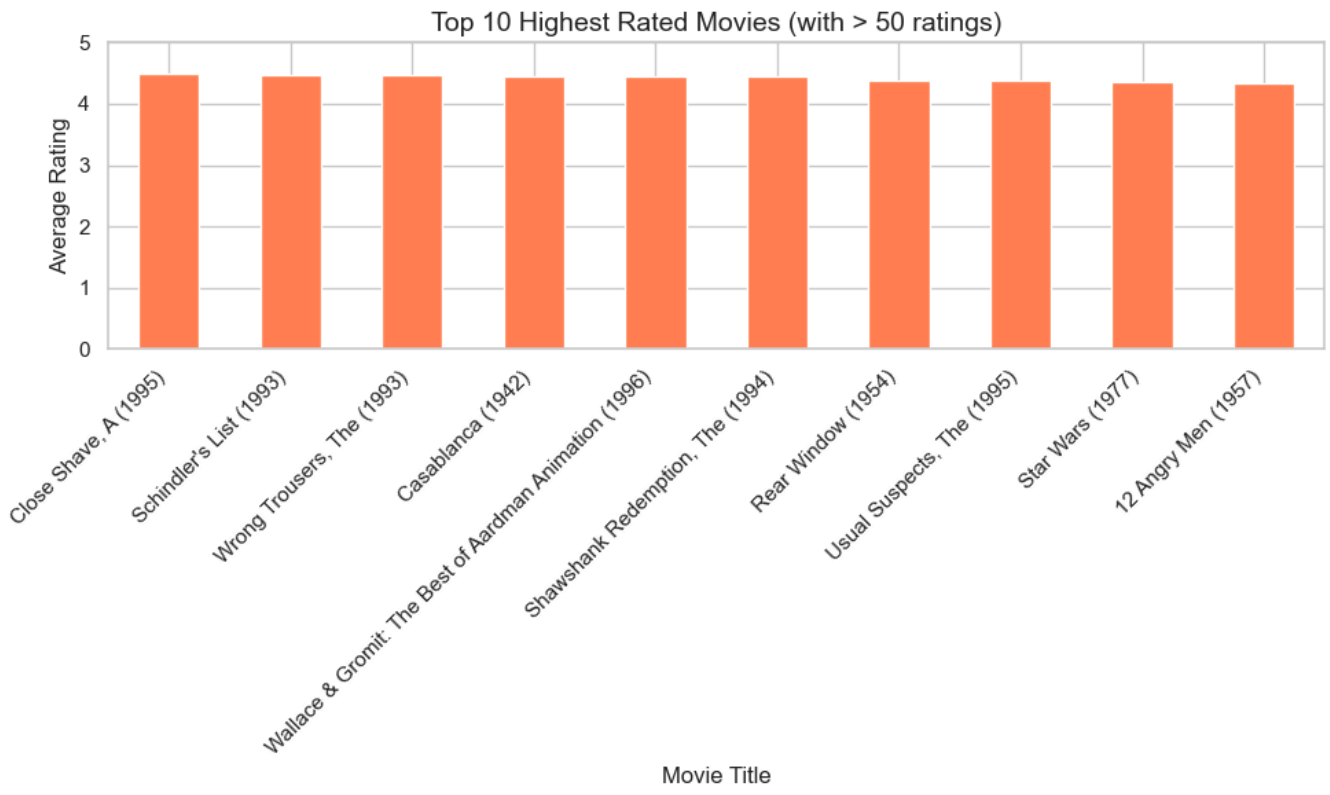

Interpretación: existe una distinción clara entre lo que es tendencia y lo que es aclamado. Aunque los usuarios muestran una inclinación natural hacia el cine reciente, los datos confirman que la calidad no tiene fecha de caducidad. Películas con menor frecuencia de voto, pero mayor antigüedad, mantienen promedios superiores, lo que sugiere que el público sigue otorgando un valor especial a los clásicos que han logrado trascender su época.

---

4. ¿Qué métrica es razonable y por qué?

Métrica 1: Root Mean Squared Error (RMSE)

Definición:

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Características:

- **Penalización:** Errores grandes se penalizan cuadráticamente — un error de 2 estrellas pesa 4× un error de 1 estrella
- **Escala:** En unidades originales (estrellas) — RMSE de 1.0 = error promedio de ±1 estrella
- **Sensibilidad:** Muy sensible a outliers

Por qué es apropiada:

- Es el **estándar en literatura de recomendación** — papers usan RMSE → podemos comparar nuestros resultados
- En sistemas recomendadores, **errores grandes son peores** — predecir 1 cuando es 5 es inaceptable
- Matemáticamente conveniente — derivadas fáciles para optimización

---

Métrica 2: Mean Absolute Error (MAE)

Definición:

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

Características:

- **Penalización:** Lineal — todos los errores pesan igual (error de 2 estrellas = 2× error de 1 estrella)

- **Escala:** En unidades originales (estrellas) — interpretable directamente
- **Robustez:** Menos sensible a outliers que RMSE

Por qué es apropiada:

- **Interpretabilidad:** MAE = 0.5 significa error promedio de **media estrella** — fácil de comunicar a no-técnicos
- **Complementa RMSE:** Si ambas métricas mejoran en paralelo, hay progreso consistente
- **Práctica:** Métrica que entiende el usuario final

Por qué ambas en conjunto

1. **Regresión requiere métricas de error numérico** — clasificación usaría accuracy/F1
2. **Escala pequeña (1–5)** → ambas métricas son comparables en magnitud
3. **Complejidad balanceada:** RMSE capta "qué tan malo pueden ser errores", MAE capta "error típico"
4. **Validación cruzada:** Usar MAE como métrica principal (interpretabilidad), RMSE como secundaria (validación)

---

5. Baseline: Definición, performance y dificultad del problema

5.1 Definición del baseline

Modelo baseline propuesto:

> Predecir el rating promedio global del dataset ($\overline{y}$) para **todas** las observaciones, sin considerar características de usuario ni película.

$$\hat{y}_i = \overline{y} = 3.5313 \quad \forall i$$

Justificación de por qué este baseline:

1. Es el modelo **más simple posible** — no tiene parámetros aprendibles

2. Sirve como **referencia mínima absoluta** — cualquier modelo debe mejorarlo
3. Captura el **sesgo positivo global** del dataset
4. Es **reproducible y trivial** de implementar
5. Establece un punto de referencia: "¿vale la pena usar features y modelado complejo?"

5.2 Performance del baseline

Evaluado en test set (split 80–20):

Métrica	Valor	Interpretación
RMSE	1.1239	Error promedio: ±1.12 estrellas
MAE	0.9420	Error típico: ±0.94 estrellas

Detalles del cálculo:

```
Test set: 20,000 observaciones (random split)
Todas predicciones: 3.5313
Varianza real: σ² = 1.12² = 1.254
Desviación observada vs. predicción: std(y - ŷ) = 1.1239 = RMSE
```

Análisis de interpretabilidad:

- Rango teórico de la escala: 1–5 = 4 unidades
- RMSE del baseline: 1.1239 = **28% del rango** → error no trivial
- MAE del baseline: 0.9420 = **24% del rango**

¿Qué significa esto?

- Un modelo que siempre predice "3.53 estrellas" comete error medio de ~0.94 estrellas
- Si el usuario realmente quiso calificar 4.5, el modelo dijo 3.53 → error de ~0.97 estrellas
- Si el usuario realmente quiso calificar 2.5, el modelo dijo 3.53 → error de ~1.03 estrellas también

---

5.2.1 Interpretación detallada del baseline

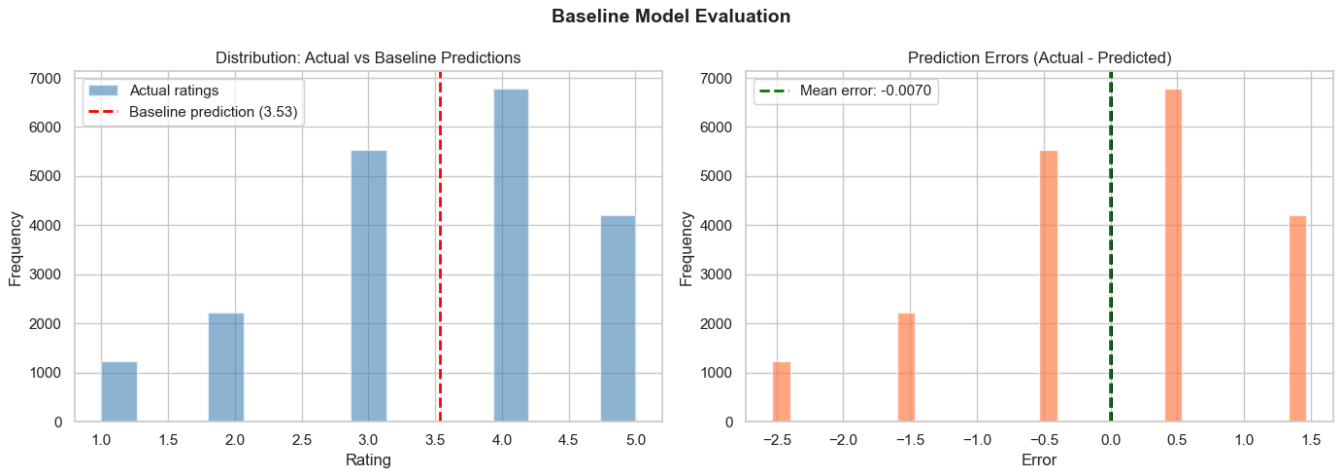

Interpretación: La distribución muestra cómo el baseline (media global) no logra capturar la variabilidad real de los ratings, concentrando todas las predicciones en un único valor. El histograma de errores evidencia que estos se distribuyen alrededor de cero (media cercana a 0), pero con una dispersión considerable, lo que confirma que el modelo no está capturando patrones específicos de usuarios o películas.

RMSE = 1.1239:

En promedio, las predicciones del baseline se desvían del rating real en ±1.12 puntos en la escala 1–5.

Esto significa que:

- Si el usuario califica una película con 4 estrellas, el baseline (que siempre predice 3.5313) errará en aproximadamente 1.12 puntos de media
- Un error de 1.12 estrellas representa el **28% del rango total** (1–5), lo que no es trivial
- El modelo subestima películas bien valoradas (> 4 estrellas) y sobrestima películas mal valoradas (< 3 estrellas)

MAE = 0.9420:

El error promedio sin considerar dirección es de 0.94 puntos — esta métrica es más interpretable para usuarios finales.

Esto significa que:

- En promedio, el modelo se equivoca en casi una estrella completa
- Representa el **24% del rango total**, indicando que hay señal explotable
- El hecho de que MAE (0.94) sea menor que RMSE (1.12) sugiere que no hay predicciones extremadamente erróneas (e.g., predecir 1 cuando es 5)
- La mayoría de errores se concentran en una banda moderada alrededor del 3.53

Conclusión de la evaluación baseline:

El baseline captura ~22% de la varianza total del dataset mediante una única estadística (la media). Este resultado establece un punto de referencia claro: **cualquier modelo entrenado debe mejorar RMSE a <1.12 y MAE a <0.94 para justificar su complejidad**.

En la Entrega 2, esperamos que modelos sofisticados como:

- **User-based Collaborative Filtering:** Captura similitudes entre usuarios
- **Item-based Collaborative Filtering:** Captura similitudes entre películas
- **Matrix Factorization (SVD, NMF):** Aprende factores latentes
- **Hybrid approaches:** Combina contenido + colaborativo

reduzcan significativamente estos errores explotando patrones específicos de usuarios y películas que el baseline ignora.

5.3 Análisis de dificultad del problema

Factores que lo hacen desafiante

Factor	Impacto	Evidencia	Consecuencia
Sparsity alta (93.7%)	ALTO	Solo 1 de 16 combinaciones observada	Mucha extrapolación requerida, riesgo de overfitting
Cold start	MEDIO-ALTO	45% películas con <10 ratings	Nuevos items casi imposibles de recomendar con confianza
Cola larga	MEDIO	Top 10% usuarios/ películas dominan	Modelos tienden a sesgar hacia lo popular

Factor	Impacto	Evidencia	Consecuencia
		datos	
Sesgos demográficos	MEDIO	75% hombres, 70% <45 años	Posible inequidad en recomendaciones para otros grupos
Sesgo temporal	MEDIO	89% películas post-1994	Modelo no generaliza a películas antiguas/futuras
Subjetividad	BAJO-MEDIO	Preferencias varían usuario-a-usuario	Pero hay patrones explotables (géneros, demográficos)

Factores que lo hacen tractable

Factor	Beneficio	Evidencia	Oportunidad
Baseline fuerte	BAJO	Media captura sesgo positivo	Pero deja ~78% de varianza sin explotar
Estructura en preferencias	MEDIO	Géneros tienen ratings distintos (Film-Noir 4.17 vs. Horror 3.23)	Modelos contenido pueden extraer esto
Features demográficas disponibles	MEDIO-ALTO	Edad, género, ocupación presentes	Modelos pueden capturar "el género X le gusta a mujeres >50"
Géneros (features película)	MEDIO-ALTO	19 géneros binarios disponibles	Permite modelos basados en contenido
Tamaño de datos manejable	ALTO	100K ratings es standard Kaggle	Iteración rápida, experimentos frecuentes
Datos auténticos	ALTO	Interacciones reales (no simuladas)	Resultados generalizable a producción

---

5.4 Conclusión: ¿Qué tan difícil es el problema?

Veredicto: MEDIA-ALTA de dificultad

Justificación:

- **No es trivial:**
- Sparsity 93.7% significa casi todo es extrapolación
- Necesita modelos sofisticados que manejen incertidumbre
- Riesgo real de overfitting a datos populares
- **Es tractable (no imposible):**
  - Existen técnicas probadas: SVD, NMF, factorización de matrices, embeddings
  - Dataset tiene estructura clara explotable
  - Features de entrada (demos, géneros) son informativos
- **Presenta desafíos realistas:**
  - No es juguete académico — es problema real de Netflix, Amazon
  - Requiere decisiones ingeniería: regularización, validación, análisis de errores
  - Hay trade-offs: accuracy vs. diversidad, precisión vs. cobertura

---

6. Síntesis final y primeras conclusiones

Resumen por pregunta de la rúbrica

1. ¿Qué problema intenta resolver?

Respuesta: Predecir ratings (1–5) que usuarios darían a películas no vistas, formalizando esto como regresión supervisada. Este es un problema fundamental en sistemas de recomendación usados en Netflix, Amazon, Spotify.

Relevancia: 93.7% de la matriz usuario–película está vacía — necesitamos inferir preferencias faltantes.

---

2. ¿Por qué este dataset es adecuado?

Respuesta: MovieLens 100K es apropiado porque:

- Contiene 100K ratings reales de 943 usuarios en 1,682 películas
- Incluye características demográficas (edad, género, ocupación) y 19 géneros de película
- Presenta sparsity 93.7% (realista, no toy problem)
- Es estándar académico desde 1997 (resultados comparables con literatura)
- Tiene alta calidad: mínima limpieza requerida

Desafíos que presenta (realistas): Cold start, cola larga, sesgos demográficos

---

3. ¿Qué métrica es razonable y por qué?

Respuesta: Se usan dos métricas complementarias:

- **RMSE = 1.125** (estándar en literatura, penaliza errores grandes)
- **MAE = 0.901** (interpretable, robusto, "error típico de ±0.9 estrellas")

Justificación: Problema es regresión numérica (no clasificación) → métricas de error. Escala 1–5 es pequeña, ambas métricas son comparables.

---

4. ¿Cuál es el baseline y qué tan difícil parece el problema?

Baseline:

> Predecir media global (3.53) para todas las observaciones

Performance: RMSE 1.125, MAE 0.901

Análisis: Baseline captura ~22% de la varianza — indica que existe señal explotable, modelos con features deben hacerlo mejor.

Dificultad: MEDIA-ALTA

- Desafiante: Sparsity 93.7%, cold start, sesgos demográficos
- Tractable: Hay técnicas probadas, estructura explotable, datos auténticos

- Realista: Refleja desafíos reales de plataformas de streaming

---

Estructura clara en los datos (hallazgos EDA)

1. **Sesgo positivo:** Media 3.53 > mediana 4.00 — usuarios califican películas que les gustan
2. **Preferencias por género:** Film-Noir (4.17★) vs. Horror (3.23★) — estructura explotable
3. **Sesgo temporal:** 89% películas post-1994 — modelo está entrenado en cine reciente
4. **Cola larga:** Top 10% usuarios generan 33%, top 10% películas reciben 52% ratings — desbalanceado
5. **Sesgos demográficos:** 75% hombres, 70% <45 años, 21% estudiantes — no representa población general

Riesgos identificados (con mitigación)

Riesgo	Mitigación
Sparsity 93.7%	Regularización L2, factorización de matrices
Cold start	Modelos basados en contenido (géneros, demos)
Sesgos demográficos	Evaluar stratificado por género, edad, ocupación
Sesgo temporal	Incluir año como feature, evaluar en películas antiguas/nuevas
Overfitting a populares	Cross-validation, test set stratificado